Risque de crédit

Travaux pratiques

Tableau de bord de risque de crédit

Application au jeu de données German Credit

Réalisé par :

KESSOU Saad

KANOUNE Mohamed Amine

Semestre 7 – Groupe G2

Table des matières

Introduction.....2
1. Présentation des données.....2
2. Exploration des données.....2
2.1 Répartition de la cible.....2
2.2 Variables numériques et segments de clientèle.....3
2.3 Corrélations.....3
3. Préparation des données et méthodologie.....3
4. Modélisation et résultats.....4
4.1 Comparaison des modèles.....4
4.2 Calibration des probabilités.....4
4.3 Choix du seuil de décision.....5
4.4 Évaluation sur le jeu de test.....5
4.5 Interprétation du modèle.....6
4.6 Parties non exécutées du notebook.....7
5. Limites.....7
Conclusion.....8

Introduction

Une banque qui accorde un crédit prend un risque : si le client ne rembourse pas, elle perd tout ou partie du capital prêté ; si elle refuse un bon client, elle renonce à un gain. Pour arbitrer entre ces deux erreurs, elle a besoin d'une estimation fiable de la probabilité de défaut de chaque demandeur.

L'objectif de ce travail est de construire, à partir du jeu de données German Credit, un petit tableau de bord de risque de crédit. La démarche suivie comprend l'exploration des données, la comparaison de plusieurs modèles de classification, la calibration des probabilités prédites, le choix d'un seuil de décision à partir d'une matrice de coûts, puis l'évaluation du modèle retenu sur un échantillon de test.

Le problème relève de l'apprentissage supervisé, et plus précisément de la classification binaire : chaque dossier est associé à une étiquette connue (bon payeur ou défaut) et le modèle apprend à la prédire à partir des caractéristiques du demandeur. Si l'on cherchait à prédire le montant des pertes, on se placerait au contraire dans le cadre d'une régression.

1. Présentation des données

Le jeu de données Statlog (German Credit Data) a été constitué par le professeur Hans Hofmann de l'Université de Hambourg et est diffusé par le dépôt UCI Machine Learning Repository. Il décrit 1 000 demandes de crédit au moyen de 20 variables, dont 7 numériques et 13 catégorielles. La variable cible distingue 700 bons payeurs de 300 mauvais payeurs, soit un taux de défaut de 30 %. Aucune valeur n'est manquante.

Les données sont chargées directement depuis l'archive officielle de l'UCI. Les modalités des variables catégorielles, codées dans le fichier d'origine (A11, A12, etc.), ont été remplacées par des libellés explicites d'après la documentation, et les variables ont été renommées en français. La cible a été recodée de sorte que « défaut » vaille 1 et « bon payeur » vaille 0.

Les échelles des variables numériques sont très différentes : le montant du crédit a une moyenne d'environ 3 271 DM alors que le taux d'effort ne prend que les valeurs de 1 à 4. Cette hétérogénéité justifie la standardisation appliquée avant l'estimation de la régression logistique. La documentation fournit également une matrice de coûts : accorder un crédit à un mauvais payeur coûte cinq fois plus que refuser un bon payeur.

2. Exploration des données

2.1 Répartition de la cible

Les classes sont déséquilibrées sans l'être de façon extrême : 30 % de défauts contre 70 % de bons payeurs. Dans ce contexte, l'exactitude (accuracy) est une mesure trompeuse, puisqu'un

modèle qui accorderait tous les crédits obtiendrait 70 % de bonnes réponses sans détecter le moindre défaut. Nous avons donc recours à une validation croisée stratifiée, qui conserve la proportion de défauts dans chaque pli, et à la PR-AUC en complément de la ROC-AUC.

2.2 Variables numériques et segments de clientèle

La comparaison des distributions selon le statut montre que les clients en défaut ont tendance à contracter des crédits plus longs et plus élevés, et qu'ils sont un peu plus jeunes en moyenne. Les distributions se chevauchent toutefois largement : aucune variable numérique ne sépare à elle seule les deux groupes, ce qui justifie le recours à un modèle multivarié.

L'examen des taux de défaut par catégorie met en évidence le rôle du compte courant. Les clients sans compte ont un taux de défaut nettement inférieur au taux global, tandis que ceux dont le compte est à découvert se situent nettement au-dessus. L'historique de crédit conduit à un résultat moins intuitif : un compte critique est associé à un risque plus faible que des retards de paiement passés, ce qui s'explique vraisemblablement par un effet de sélection, ces clients ayant déjà obtenu d'autres crédits. Ces taux décrivent des associations et non des relations de cause à effet.

2.3 Corrélations

La durée et le montant du crédit sont corrélés entre eux, un crédit long étant le plus souvent un crédit élevé, et ce sont aussi les deux variables numériques les plus liées au défaut. Les corrélations avec la cible restent néanmoins modestes : l'information utile est répartie sur de nombreuses variables, y compris catégorielles.

3. Préparation des données et méthodologie

L'échantillon est séparé en un jeu d'entraînement de 750 dossiers et un jeu de test de 250 dossiers, avec stratification sur la cible de façon à conserver 30 % de défauts dans chacun. Le jeu de test n'est utilisé qu'une seule fois, à la fin, pour l'évaluation finale.

Toutes les transformations (standardisation des variables numériques, encodage one-hot des variables catégorielles) sont regroupées dans un Pipeline de scikit-learn et apprises uniquement sur les données d'entraînement. Cette précaution évite toute fuite de données (data leakage), qui fausserait l'estimation des performances. Aucune imputation n'est nécessaire puisqu'il n'y a pas de valeurs manquantes.

Trois approches sont comparées, de la plus simple à la plus complexe : une référence qui prédit toujours la proportion de défauts observée à l'entraînement, une régression logistique, modèle usuel du scoring de crédit et facile à expliquer, et une forêt aléatoire de 300 arbres capable de capturer des interactions non linéaires. La comparaison s'appuie sur une validation

croisée stratifiée à cinq plis réalisée sur l'ensemble d'entraînement, avec trois métriques : la ROC-AUC, la PR-AUC et le score de Brier.

4. Modélisation et résultats

4.1 Comparaison des modèles

Le tableau 1 présente les résultats de la validation croisée. La référence, sans aucun pouvoir de tri, donne une ROC-AUC de 0,5 et une PR-AUC égale à la proportion de défauts. Les deux modèles appris font nettement mieux. La forêt aléatoire obtient la meilleure ROC-AUC (0,784 contre 0,765) avec un écart-type plus faible d'un pli à l'autre, mais l'écart avec la régression logistique reste faible au regard de cette variabilité, ce qui est fréquent sur un échantillon de cette taille.

Tableau 1 : Résultats de la validation croisée à 5 plis (jeu d'entraînement)

Modèle	ROC-AUC	PR-AUC	Brier
Forêt aléatoire	0,784 (±0,012)	0,592 (±0,029)	0,170
Régression logistique	0,765 (±0,036)	0,592 (±0,039)	0,173
Référence	0,500	0,300	0,210

4.2 Calibration des probabilités

Un modèle est calibré lorsque, parmi les clients auxquels il attribue une probabilité de défaut de 20 %, environ 20 % font effectivement défaut. Cette propriété est indispensable pour fixer un seuil de décision à partir de coûts. La régression logistique est en général assez bien calibrée par construction, alors que la forêt aléatoire produit souvent des probabilités trop resserrées autour de la moyenne. Nous avons donc comparé la forêt brute à deux versions calibrées, par la méthode de Platt (sigmoïde) et par régression isotonique, à l'aide de prédictions hors échantillon.

Tableau 2 : Effet de la calibration (prédictions hors échantillon, jeu d'entraînement)

Modèle	ROC-AUC	PR-AUC	Brier
Forêt aléatoire + Platt	0,790	0,580	0,165
Forêt aléatoire + isotonique	0,790	0,588	0,166
Forêt aléatoire (brute)	0,786	0,579	0,170
Régression logistique	0,766	0,587	0,173

Comme le montre le tableau 2, la calibration améliore le score de Brier sans modifier sensiblement le classement des clients, ce qui est attendu puisqu'elle conserve l'ordre des scores. La forêt aléatoire calibrée par la méthode de Platt présente le meilleur score de Brier (0,165) et a

été retenue comme modèle final. Le gain reste modeste, et la différence avec la version isotonique est négligeable.

4.3 Choix du seuil de décision

La banque doit transformer la probabilité en décision : le crédit est refusé si la probabilité de défaut dépasse un seuil. Avec un coût de 1 pour le refus d'un bon client et de 5 pour l'octroi à un mauvais payeur, le seuil théorique qui minimise le coût attendu, si les probabilités sont bien calibrées, vaut 1/(1+5), soit environ 0,167. Le seuil optimal recherché empiriquement sur les prédictions hors échantillon de l'entraînement est de 0,16, ce qui est cohérent avec la théorie.

À ce seuil, le coût total sur l'entraînement est de 378, contre 690 avec le seuil usuel de 0,5, soit une baisse d'environ 45 %. Le seuil de 0,5 est donc inadapté lorsque les erreurs n'ont pas le même coût. La courbe de coût est par ailleurs assez plate autour de son minimum : se situer dans la bonne zone importe davantage que la valeur exacte.

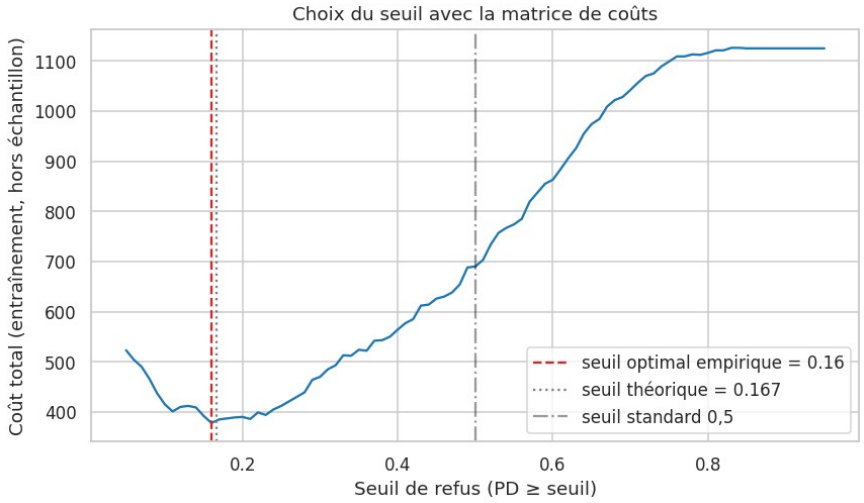


Figure 1 : Coût total en fonction du seuil de refus

4.4 Évaluation sur le jeu de test

Le modèle retenu est évalué une seule fois sur les 250 dossiers de test, avec le seuil de 0,16. Les résultats sont résumés dans le tableau 3.

Tableau 3 : Performances du modèle final sur le jeu de test

Indicateur	Valeur
ROC-AUC	0,802
PR-AUC (référence : 0,30)	0,626
Score de Brier	0,160
Coût total du modèle	127
Coût si tous les crédits sont accordés	375

La ROC-AUC obtenue sur le test (0,802) est cohérente avec celle de la validation croisée (environ 0,79), ce qui n'indique pas de surapprentissage notable. La matrice de confusion (tableau 4) montre que le modèle détecte 68 des 75 défauts, soit un rappel d'environ 91 %, pour une précision de 42 % sur cette classe. Le taux de refus est de 64 % (160 refus sur 250 dossiers).

Tableau 4 : Matrice de confusion sur le jeu de test (seuil = 0,16)

Statut réel	Crédit accordé	Crédit refusé
Bon payeur	83	92
Défaut	7	68

Le coût total s'élève ainsi à 7 × 5 + 92 × 1 = 127, contre 375 pour une banque qui accorderait tous les crédits, soit une réduction d'environ 66 %. Le compromis est assumé : le modèle refuse de nombreux bons clients, dont l'erreur coûte peu, pour éviter presque tous les défauts, dont l'erreur coûte cher. Un taux de refus de 64 % serait toutefois très pénalisant sur le plan commercial, ce qui rappelle qu'une matrice de coûts limitée aux seules erreurs de classement simplifie la réalité.

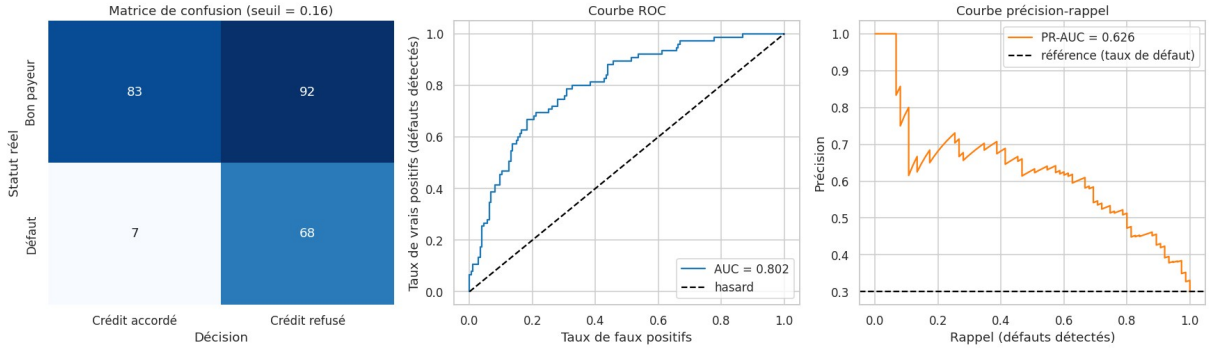


Figure 2 : Matrice de confusion, courbe ROC et courbe précision-rappel (jeu de test)

4.5 Interprétation du modèle

Pour interpréter les facteurs de risque, nous avons ajusté une régression logistique sur l'entraînement et examiné ses coefficients (figure 3). Parmi les modalités qui augmentent le plus le risque figurent le crédit destiné aux études, l'absence de patrimoine connu, une épargne inférieure à 100 DM, un compte courant à découvert, le statut de travailleur étranger et la situation de locataire. À l'inverse, l'absence de compte courant, un compte critique, une épargne supérieure ou égale à 1 000 DM et une ancienneté d'emploi de quatre à sept ans sont associées à un risque plus faible.

Ces coefficients traduisent des associations statistiques et non des causes. Les modalités rares ont des coefficients instables, et certains signes sont contre-intuitifs (une épargne inconnue, par exemple, est associée à un risque plus faible), ce qui renvoie encore à des effets de sélection dans l'échantillon.

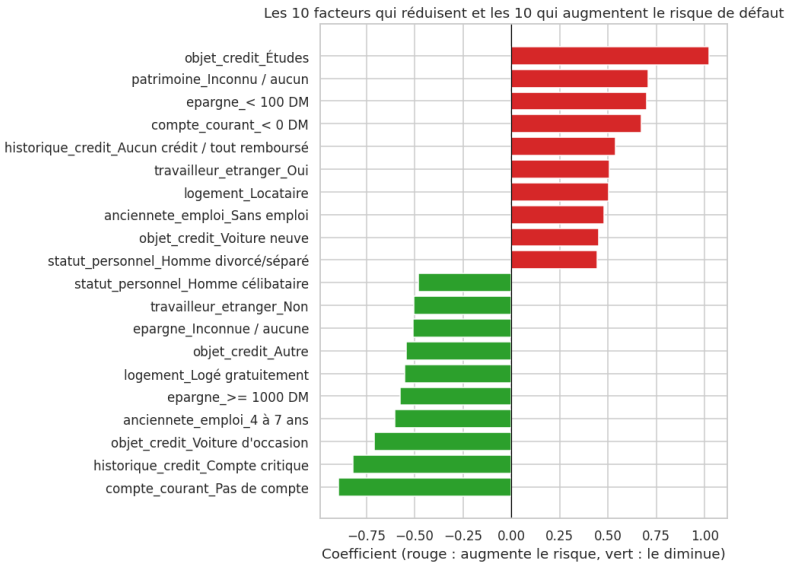


Figure 3 : Coefficients de la régression logistique (10 modalités les plus protectrices et 10 les plus aggravantes)

4.6 Parties non exécutées du notebook

Dans le fichier analysé, les cellules situées à partir de l'importance par permutation (section 10.2) jusqu'au scoring d'un nouveau dossier (section 13) ne présentent aucune sortie enregistrée. Il s'agit de l'importance par permutation, de la grille de notation en cinq classes de risque, du tableau de bord synthétique, de l'audit d'équité par tranche d'âge et par statut personnel, et de l'exemple de scoring. Leurs résultats ne sont donc pas commentés ici, et le notebook devra être réexécuté intégralement avant son rendu.

5. Limites

Plusieurs limites doivent être gardées à l'esprit. D'abord, la taille de l'échantillon est réduite : avec 1 000 dossiers, dont seulement 75 défauts dans le jeu de test, les estimations du seuil, des taux par classe et des importances sont bruitées, et un autre découpage donnerait des chiffres différents. Ensuite, les données datent des années 1990 et concernent des clients allemands, les montants étant exprimés en deutsche mark : les comportements, les produits et les taux ont depuis changé, et le modèle devrait être revalidé sur des données récentes.

Le jeu de données souffre en outre d'un biais de sélection, puisque seuls les clients ayant obtenu un crédit y figurent. Les demandeurs refusés sont absents, ce qui biaise l'apprentissage (problème dit de l'inférence des refusés). Enfin, des variables comme l'âge, le sexe ou le statut de travailleur étranger sont sensibles et leur usage est encadré, voire interdit, dans de nombreuses juridictions ; l'équité des décisions entre groupes doit donc être mesurée, ce qui exige des effectifs bien plus importants que ceux disponibles ici. La fuite de données a en revanche été maîtrisée : les transformations sont apprises dans un Pipeline, le seuil est fixé hors échantillon et le jeu de test n'est utilisé qu'une fois.

Conclusion

Ce travail a permis de mettre en œuvre une démarche complète de modélisation du risque de crédit : exploration des données, préparation sans fuite d'information, comparaison à une référence, validation croisée stratifiée, calibration des probabilités, choix d'un seuil fondé sur les coûts et évaluation unique sur un jeu de test. La forêt aléatoire calibrée par la méthode de Platt atteint une ROC-AUC de 0,80 et une PR-AUC de 0,63 sur le test, et réduit d'environ deux tiers le coût par rapport à une politique d'octroi systématique, au prix d'un taux de refus élevé.

Plusieurs prolongements sont envisageables : tester un modèle de gradient boosting, régler la régularisation de la régression logistique, répéter l'évaluation sur plusieurs découpages avec des intervalles de confiance, refaire l'analyse sans les variables sensibles, ou encore calculer une perte attendue par client (PD × LGD × EAD). Le modèle reste toutefois pédagogique et ne doit pas servir à de véritables décisions de crédit.